

ai | ÚSTAV AUTOMATIZACE
A INFORMATIKY



uai.fme.vutbr.cz

DLAD

Deep Learning based Automatic Detection

for Major Thoracic Diseases on Chest Radiographs

Martin Juříček, VAI 2021

OBSAH

ÚVOD DO PROBLEMATIKY

ÚVOD DO DLAD

PŘEDZPRACOVÁNÍ RENTGENOVÝCH SNÍMKŮ

ARCHITEKTURA DLAD

NASTAVENÍ DLAD

DLAD VS RADIOLOG

PŘÍKLADY NAsAZENÍ

ZÁVĚR

PŘÍNOS

ÚVOD DO PROBLEMATIKY

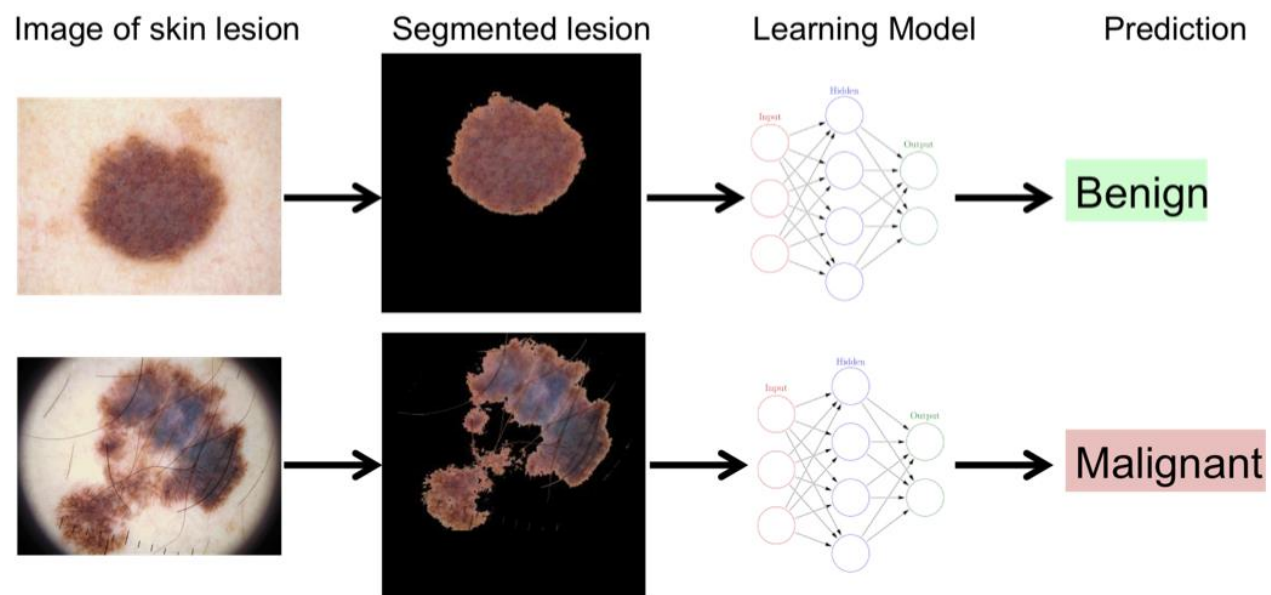


- Snímání rentgenových snímků tvoří jednu z nejčastěji prováděných metod radiologického vyšetření.
- K přesné a precizní diagnostice je potřeba zkušenosti a odborné znalosti, jelikož různé anatomické struktury se mohou překrývat v samotném snímku(2D), přičemž různé fyziologické a patologické změny se mohou jevit jako velmi podobné.
- Radiologové čelí těžkému úkolu, kdy je podle zdrojů [1] pravděpodobnost chyby až cirka 22 %.
- V této oblasti byly vyvinuty a jsou i částečně používané systémy **CAD**(Computer-Aided Diagnosis), které kombinují prvky umělé inteligence, počítačového vidění s radiologickým a patologickým zpracováním obrazu.
- Některé **CAD** systémy dosáhly úspěšných výsledků při detekci u různých onemocnění hrudníku, včetně plicních uzlin, plicní tuberkulózy, či pneumotorax¹.
- Jedna z technik umělé inteligence **DL**(Deep Learning) prokázala slibné výsledky při zpracování obrazu a následné lékařské diagnostice, např. při detekci diabetické retinopatie² na snímcích fundusu či klasifikace rakoviny kůže z přiblížených fotografií kůží.


1] pneumothorax - nahromadění vzduchu či jiného plynu v uzavřeném prostoru obklopující plíce.

2] diabetická retinopatie - poškození sítnice oka způsobené diabetem, může vést až ke ztrátě zraku.

ÚVOD DO PROBLEMATIKY



Zjednodušený proces k určení rakoviny kůže



Příklad použití CAD systému

ÚVOD DO DLAD



- **Původ:** Seoul National University College of Medicine
- **Cíl:** diagnostika nejběžnějších hrudních onemocnění z rentgenových snímků
- **Hlavní cíl:** binární klasifikace rentgenových snímků s abnormálními nálezy definovaných hrudních onemocnění
- **Definovaná onemocnění:** rakovina plic, tuberkulóza, zápal plic, pneumotorax
- **Vstupní data:** na vývoj bylo poskytnuto v součtu cirka 100 000 rentgenových snímků (zhruba 60 000 rentgenových snímků bylo s normálními výsledky, zbylých 40 000 rentgenových snímků s abnormálními nálezy)
- Data byly ověřeny radiology se zkušenostmi v praxi v rozsahu 7-14 let.
- Data byly sesbírány z 5 zdravotních center.
- Data byly rozděleny na:
 - 1] tréninkové: 53 621 s normálními výsledky a 34 074 s abnormálními nálezy
 - 2] ladící: 300 s normálními výsledky a 750 s abnormálními nálezy
 - 3] validační: 300 s normálními výsledky a 789 s abnormálními nálezy



PŘEDZPRACOVÁNÍ RTG SNÍMKŮ



- **Techniky předzpracování:** úprava obrazu jako je například geometrické zvětšení (horizontální převrácení, vertikální převrácení, oříznutí obrazu či různé rotace obrazu), případně fotometrické úpravy jako je například úprava jasu, úprava kontrastu, náprava obrazového šumu¹, gama correction², a jiné.
- Toto zpracování obrazu bylo aplikováno na každý z tréninkových rentegenových snímků, před použitím jako vstup do umělé neuronové sítě.
- Tyto úpravy jsou nezbytné, pomáhají síti mnohem lépe fungovat, proti různým velikostem lézí, geometrii či samotných nepříznivým obrazovým podmínkám.



Gamma correction



Příklad obrazového šumu, specifictěji „salt and pepper noise“

1] obrazový šum – je náhodná variace jasu nebo barevných informací v obrazech, přičemž tento šum může vznikat při snímání například různými senzory, fotoaparáty či jinou elektronikou.

2] gama correction – je transformace obrazu kdy dochází k úpravě celkového jasu obrazu. Nesprávně opravené obrázky mohou vypadat vybledlé nebo příliš tmavé.

ARCHITEKTURA DLAD





- **Vstup:** rentgenový snímek
- **Výstup:** spojitá hodnota v intervalu 0 a 1 jakožto pravděpodobnost rentgenového snímku s abnormálními nálezy a pravděpodobnosti lokalizace definované choroby
- 1 páteřní síť¹ a 5 paralelních klasifikátorů
- Páteřní síť se skládala ze 120 konvolučních vrstev se 4 dense bloky², které jako vstup využívají rentgenový snímek a generují mapu funkcí³.
- Mapa funkcí je poté použita pro paralelní klasifikátory a ty následně generují mapy pravděpodobnosti pro každou třídu.
- Pro definované onemocnění byly navrženy 4 klasifikátory s konečným klasifikátorem, který je určen pro jakoukoli chorobou.
- K trénování byly použity 2 ztrátové funkce: klasifikační ztráta a lokalizační ztráta

1] páteřní síť (backbone network) – je termín v oboru AI, který popisuje síť, která má vstup obrázků a z něj extrahuje mapu funkcí. Na této mapě funkcí je pak založen zbytek konvoluční neuronové sítě.


2] dense bloky - je modul používaný v konvolučních neuronových sítích, který spojuje všechny vrstvy (s odpovídajícími velikostmi map funkcí) přímo mezi sebou.

3] mapa funkcí – jedná se o mapování kde se určité druhy prvků nachází na daném obrázku.

ARCHITEKTURA DLAD



Nákres architektury DLAD



Náčrt prostupu rentgenového snímku neuronovou sítí

NASTAVENÍ DLAD



- Trénovatelné parametry je vhodné inicializovat náhodně pomocí Gaussovy distribuce.
- Optimalizační algoritmus: SGD¹(Stochastic gradient descent)
- Minibatch²: 64
- Learning rate³: 0.01
- Po 30 epochách⁵ je snížena rychlost učení z 0.01 na 0.001, přičemž modely byly trénovány až do 40 epoch.
- Pro další zlepšení byly zobecněny 3 sítě využívající stejná data, avšak různými hyperparametry.
- Tyto sítě byly následně nezávisle trénovány, tak aby výsledky mohly být dále zprůměrovány a posloužily k výslednému nastavení.

1] SGD – je optimalizační metoda k nalezení optimální konfigurace parametrů pro algoritmus UI. Iterativně provádí malé úpravy konfigurace umělé neuronové sítě, aby se snížila chyba sítě.

2] minibatch – Mini dávka znamená, že během jedné iterace se vezme pouze podmnožina všech svých dat pro výpočet gradientu.

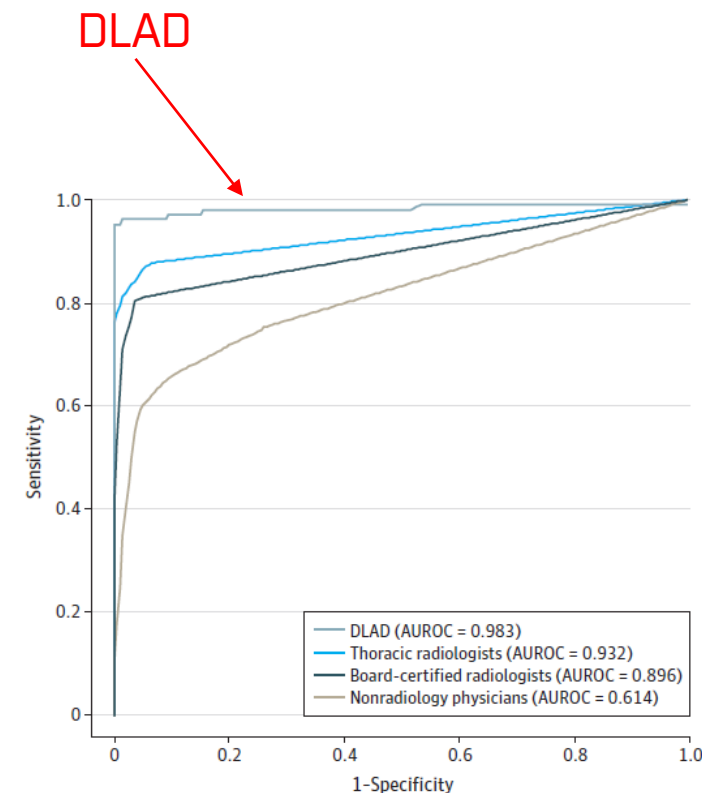
3] learning rate – rychlost učení určuje velikost kroku při každé iteraci a zároveň je definován tak, že se pohybuje směrem k minimální ztrátové funkci.

5] epocha – představuje jeden průchod celou tréninkovou sadou.

DLAD VS RADIOLOG



- Ke komparaci je použit graf AUROC¹.
- Pro obrazovou klasifikaci byly dosaženy výsledky[2]:
 - AUROC skóre lékaře: 0.614
 - AUROC skóre certifikovaných radiologů: 0.896
 - AUROC skóre hrudních radiologů: 0.932
 - **AUROC skóre DLAD: 0.983**
- Dle skóre AUROC, DLAD prokazatelně vykazuje lepší výsledky. Jeho výsledek je znatelně lepší jak při komparaci s lékařem, kde AUROC skóre je o 0.369 vyšší. Kdežto při komparaci se zkušenými radiology je výsledek jen o 0.051 vyšší.



¹) AUROC (Area Under the Receiver Operating Characteristic curve) – graf popisující kvalitu binárního klasifikátoru v závislosti na nastavení jeho klasifikačního prahu. Definovat jako dobře fungující klasifikátor můžeme takový, u kterého oblast pod křivkou vyplňuje celou oblast grafu v celém rozsahu, čili AUROC = 1.

PŘÍKLADY NASAZENÍ




Příklad 1

- **Diagnóza:** pneumothorax
- **Pravděpodobnost:** 0.463
- Tento rentgenový snímek označili 4 z 15 radiologů a lékařů, jako normální výsledek.
- Po bližším prozkoumání se opravdu jedná o nález pneumothorax.



Příklad 2


- **Diagnóza:** tuberkulóza
- **Pravděpodobnost:** 0.9663
- Tento rentgenový snímek hrudníku ukazuje kavitární hmotu s několika satelitními uzlíky v pravé horní oblasti plic.



ZÁVĚR



- DLAD prokázal slibné výsledky pro další práci a možnost detekce i méně často obvyklých chorob. Výsledkem může být poměrně přesný nástroj, který analyzuje rentgenové snímky a tak pomůže usnadnit práci radiologům, kteří budou moci s téměř bezprecedentní přesností diagnostikovat případné onemocnění.
- Do roku 2021 od původní publikace z roku 2019 došlo již k několika modifikacím DLAD pro specifické úkoly diagnostiky např.
 - *for Reducing Overlooked Lung Cancers on Chest Radiographs*(pro snížení přehlížených rakovin plic na rentgenových snímcích hrudníku)
 - *for Malignant Pulmonary Nodules on Chest Radiographs*(pro maligní plicní uzliny na rentgenových snímcích hrudníku)
- Na cloudu je možné ověřit algoritmus DLAD a jeho funkčnost, nahráním souboru ve formátu DICOM
 - <https://insight.lunit.io>



PŘÍNOS



- Využití algoritmů umělé inteligence v medicíně naskýtá široké pole působnosti, především využití umělých neuronových sítí, které nabývají v posledních letech nebývalé popularity. Neuronové sítě mohou sloužit jako velmi schopný nástroj, jelikož jednou z jejich hlavních předností je klasifikace a predikce, což může být použito například především při lékařské diagnostice (nevýhodou jsou těžko dostupná data, které lékařské subjekty nerady propůjčují pro výzkumné účely).
- Algoritmy umělé inteligence lze však aplikovat i například pro operující roboty, nebo pro zobrazovací techniku u různých typů operací.



ZDROJE

1. Donald JJ, Barnard SA. Common patterns in 558 diagnostic radiology errors. *J Med Imaging Radiat Oncol*. 2012; **56**(2), 173-178. doi:[10.1111/j.1754-9485.2012.02348.x](https://doi.org/10.1111/j.1754-9485.2012.02348.x)
2. PARK, Sunggyun a Kwang-Nam JIN. et al. Development and Validation of a Deep Learning–Based Automated Detection Algorithm for Major Thoracic Diseases on Chest Radiographs. *JAMA Network Open* [online]. 2019, **2**(3) [cit. 2021-03-08]. ISSN 2574-3805. Dostupné z: <https://doi.org/10.1001/jamanetworkopen.2019.1095>
3. JANG, Sowon, Hwayoung SONG, Yoon SHIN, et al. Deep Learning–based Automatic Detection Algorithm for Reducing Overlooked Lung Cancers on Chest Radiographs. *Radiological Society of North America* [online]. 2020, **3**(296), 652-661 [cit. 2021-03-08]. ISSN 0033-8419. Dostupné z: <https://doi.org/10.1148/radiol.2020200165>
4. HWANG, Eui Jin, Sunggyun PARK, Kwang-Nam JIN, et al. Development and Validation of a Deep Learning–based Automatic Detection Algorithm for Active Pulmonary Tuberculosis on Chest Radiographs. *Clinical Infectious Diseases* [online]. 2019, **5**(69), 739–747 [cit. 2021-03-08]. Dostupné z: <https://doi.org/10.1093/cid/ciy967>
5. *Measuring Performance: AUC (AUROC)* [online]. 2020 [cit. 2021-03-08]. Dostupné z: <https://glassboxmedicine.com/2019/02/23/measuring-performance-auc-auroc/>
6. *Stochastic Gradient Descent* [online]. DeepAI [cit. 2021-03-08]. Dostupné z: <https://deepai.org/machine-learning-glossary-and-terms/stochastic-gradient-descent>

ai | ÚSTAV AUTOMATIZACE
A INFORMATIKY



uai.fme.vutbr.cz